Modelos de Regressão para Dados de Contagem com R

Prof. Dr. Walmes M. Zeviani Eduardo E. Ribeiro Jr Prof. Dr. Cesar A. Taconelli

Laboratório de Estatística e Geoinformação Departamento de Estatística Universidade Federal do Paraná

9 de maio de 2016 edujrrib@gmail.com

Disponibilização



Modelos de Regressão para Dados de Contagem com r - MRDCr

Conteúdo

- Introdução
- 2. Modelos Lineares Generalizados
- 3. Modelo de Regressão Poisson
- 4. Modelo de Quase-Verossimilhança
- 5. Modelos Paramétricos Alternativos
 - 5.1 Modelo Binomial Negativa

- 5.2 Modelo Poisson-Generalizada
- 5.3 Modelo COM-Poisson
- 5.4 Modelo Gamma-Count
- 6. Modelos para Excesso de Zeros
 - 6.1 Modelos de Barreira Hurdle
 - **6.2** Modelos de Mistura (*Zero Inflated*)
- 7. Modelos com Efeitos Aleatórios

Introdução

Modelos Lineares Generalizados

Modelo de Regressão Poisson

Modelo de Quase-Verossimilhança

Modelos Paramétricos Alternativos

Modelos Paramétricos Alternativos **Modelo Binomial Negativa**

Modelos Paramétricos Alternativos **Modelo Poisson-Generalizada**

Modelos Paramétricos Alternativos **Modelo COM-Poisson**

Distribuiçao COM-Poisson I

- ▶ Nome COM-Poisson, advém de seus autores **CO**nway e **M**axwell (também é chamada de distribuição Conway-Maxwell-Poisson).
- ▶ Proposta em um contexto de filas [?], essa distribuição generaliza a Poisson com a adição de um parâmetro.

Razão de probabilidades consecutivas

Distribuição Poisson

$$\frac{P(Y = y - 1)}{P(Y = y)} = \frac{y}{\lambda}$$

► Distribuição COM-Poisson

$$\frac{P(Y = y - 1)}{P(Y = y)} = \frac{y^{\nu}}{\lambda}$$

Distribuiçao COM-Poisson II

Densidade de probabilidade

$$Pr(Y=y\mid \lambda,\nu) = \frac{\lambda^y}{(y!)^\nu Z(\lambda,\nu)}, \quad \text{em que } Z(\lambda,\nu) = \sum_{j=0}^\infty \frac{\lambda^j}{(j!)^\nu}; e \quad \lambda > 0, \ \nu \geqslant 0$$

Propriedades

$$P(Y=y-1) = \frac{y^{\nu}}{\lambda}$$

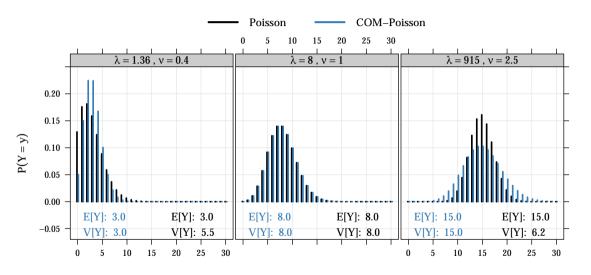
$$ightharpoonup$$
 $E(Y) \approx \lambda^{\frac{1}{\nu}} - \frac{\nu - 1}{2\nu}$

$$V(Y) \approx \frac{1}{2}E(Y)$$

Casos particulares

- ▶ Distribuição Poisson, quando $\nu = 1$
- lacktriangle Distribuição Bernoulli, quando $u
 ightarrow \infty$
- Distribuição Geométrica, quando
 ν = 0. λ < 1

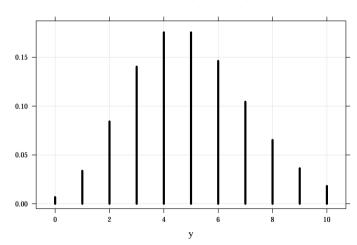
Distribuiçao COM-Poisson III



Casos Particulares

COM-Poisson (
$$\lambda = 5$$
, $\nu = 1$)

- Poisson v = 1
- Bernoulli $\nu \to \infty$
- ▶ Geométrica v = 0, $\lambda < 1$



0.0 -

0.0

Casos Particulares

- Poisson v = 1
- ▶ Bernoulli $\nu \to \infty$
- ▶ Geométrica v = 0, $\lambda < 1$



COM-Poisson ($\lambda = 3$, $\nu = 20$)

1.0

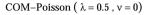
1.5

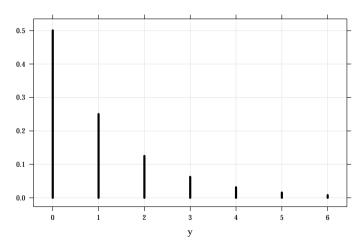
0.5

2.0

Casos Particulares

- Poisson v = 1
- Bernoulli $v \to \infty$
- Geométrica v = 0, $\lambda < 1$





Modelo de Regressão COM-Poisson

▶ Incorporando covariáveis em λ da forma $\lambda_i = \exp(X_i \beta)$, em que X_i é o vetor de covariáveis do i-ésimo indivíduo e β o vetor de parâmetros.

Função de verossimilhança

$$\begin{split} L(\lambda,\nu;\underline{y}) &= \prod_{i}^{n} \left(\frac{\lambda_{i}^{y_{i}}}{(y_{i}!)^{\nu}} Z(\lambda_{i},\nu)^{-1} \right) \\ &= \lambda_{i}^{\sum_{i}^{n} y_{i}} \prod_{i}^{n} \frac{Z(\lambda_{i},\nu)^{-1}}{(y_{i}!)^{\nu}} \end{split}$$

Função de log-verossimilhança

$$\begin{split} l(\lambda, \nu, \underline{y}) &= \log \left(\lambda_i^{\sum_i^n y_i} \prod_i^n \frac{Z(\lambda_i, \nu)^{-1}}{(y_i!)^{\nu}} \right) \\ &= \sum_i^n y_i \log(\lambda_i) - \nu \sum_i^n \log(y!) - \sum_i^n \log(Z(\lambda_i, \nu)) \end{split}$$

Estudos de caso

Vignette compoisson.html

capdesfo: número de capulhos sob efeito de desfolha (sub)

capmosca: número de capulhos sob exposição à mosca branca (sub)

ninfas : número de ninfas de mosca branca em plantas de soja (super)

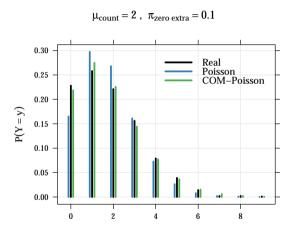
Modelos Paramétricos Alternativos **Modelo Gamma-Count**

Modelos para Excesso de Zeros

Excesso de Zeros I

- ► Casos em que a proporção de valores nulos na amostra é superior àquela estimada por um modelo de contagem. No caso Poisson $e^{-\lambda}$
- ► Geralmente contagens com um número excessivo de valores nulos apresentam superdispersão (ocasionada pelo excesso de zeros).
- ▶ Os modelos mais flexíveis abordados não capturam esse excesso de zeros e não se ajustam adequadamente.

Excesso de Zeros II



10

 $\mu_{count} = 5$, $\pi_{zero\ extra} = 0.15$

0.15 -

0.10

0.05

0.00

Gerador de excesso de zeros I

- Uma limitação das abordagens estudadas é que as contagens nulas e não nulas são provenientes do mesmo processo gerador dos dados.
- ▶ Para dados com excesso de zeros, é razoável a suposição da haver mais de um processo gerador atuando na geração dos dados.
- Assim a ocorrência de valores nulos pode ser caracterizada como:
 - **zeros estruturais**: Ausência de determinada característica da população.
 - ▶ zeros amostrais: Ocorrem segundo um processo gerador de contagens (e.g Processo Poisson)

Gerador de excesso de zeros II

Exemplo. Um estudo que visa avaliar a quantidade de produtos comprados em um mercado por uma família na última semana. A variável de interesse é o número de itens comprados.

- zeros estruturais: Se a família não foi ao mercado na última semana. Inevitavelmente o número de produtos será 0.
- **zeros amostrais:** A família foi ao mercado, porém não adquiriu nenhum produto.

Modelando contagens com excesso de zeros

Como há dois processos que geram os valores da população, na modelagem deve-se considerar ambos. As principais abordagens nestes casos são via:

- ▶ **Modelos de barreira** (*Hurdle Models*): que desconsidera os zeros amostrais e modela os zeros estruturais e as contagens positivas de forma hierárquica (seção ??); e
- ▶ Modelos de mistura (Zero Inflated Models): que modela os zeros (estruturais e amostrais) em conjunto com as contagens positivas de forma conjunta (??).

Modelos para Excesso de Zeros **Modelos de Barreira** *Hurdle*

Modelo Hurdle I

- Consideram somente os zeros estruturais;
- São chamados também de modelos condicionais, hierárquicos ou de duas partes;
- ▶ A variável de interesse é particionada em contagens nulas e não nulas;
- Esta abordagem combina um modelo de contagem truncado à esquerda do ponto y = 1 e um modelo censurado à direita no mesmo ponto y = 1

Modelo Hurdle II

Distribuição de probabilidades

$$Pr(Y = y) = \begin{cases} f_z(0) & \text{se } y = 0, \\ (1 - f_z(0)) \frac{f_c(Y = y)}{1 - f_c(Y = y)} & \text{se } y = 1, 2, \dots \end{cases}$$

em que f_z é uma função de probabilidades degenerada no ponto 0 e f_c um função de probabilidades de uma variável Y^* , como a Poisson.

Momentos da distribuição

Média

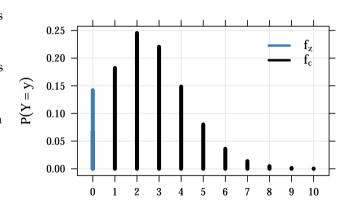
$E(Y) = \frac{E(Y^*)(1 - f_z(0))}{1 - f_c(Y = 0)}$

Variância

$$V(Y) = \frac{1 - f_z(0)}{1 - f_c(Y = 0)} \left[E(Y^*) \frac{(1 - f_z(0))}{1 - f_c(Y = 0)} \right]$$

Modelos de barreira

- f_z é uma função de probabilidades degenerada no ponto y = 0, ou seja, tem toda massa no ponto 0.
- f_c é uma função de probabilidades tradicional, que no modelo é truncada em y = 1.
- Os modelos de barreira combinam f_z e f_c para descrever Y
- Para a parte positiva os dados ainda podem apresentar sub, superdispersão ou excesso de valores em outro ponto.



Combinações comuns

Pode-se propor diferentes distribuições para f_z e f_c . Uma escolha natural para f_z é a Bernoulli e para f_c a Poisson. Assim

$$\begin{aligned} f_z &\sim \text{Bernoulli}(\pi) \\ f_c &\sim \text{Poisson}(\lambda) \end{aligned} \quad \Rightarrow \quad P(Y = y) = \begin{cases} 1 - \pi & \text{se } y = 0, \\ \pi \left(\frac{e^{-\lambda} \lambda^y}{y!(1 - e^{-\lambda})} \right) & \text{se } y = 1, 2, \dots \end{cases}$$

Embora essa escolha de modelo seja o que tem o maior suporte computacional, ressalta-se que outras distribuições podem ser escolhidas para ambas as partes f_z e f_c .

Modelos de regressão Hurdle I

- ▶ Incorporando covariáveis em f_z e f_c na forma $h(Z\gamma)$ e $g(X\beta)$, respectivamente.
- As funções h(.) e g(.), são as funções de ligação escolhidas conforme modelos f_z e f_c .
- ▶ O modelo de regressão *Hurdle* terá, portanto, os vetores de parâmetros β , γ e potencialmente ϕ (caso um modelo com parâmetro de dispersão for considerado)
- ► Se os modelos para f_z e f_c e as respectivas matrizes Z e X forem as mesmas, o teste H_0 : $\beta = \gamma$ avalia a a necessidade do modelo Hurdle.

Modelos de regressão Hurdle II

Função de verossimilhança

$$L(\underline{\theta}; \underline{y}) = \prod_{i=1}^{n} (1 - 1) \left(f_{z_i}(0) \right) \cdot$$
$$\prod_{i=1}^{n} 1 \left((1 - f_{z_i}(0)) \left(\frac{f_{c_i}(y_i)}{1 - f_{c_i}(0)} \right) \right)$$

Função de log-verossimilhança

$$\begin{split} \underline{r}\underline{y}) &= \prod_{i=1}^{n} (1-1) \left(f_{z_i}(0) \right) \cdot \\ &\prod_{i=1}^{n} \mathbb{1} \left((1-f_{z_i}(0)) \left(\frac{f_{c_i}(y_i)}{1-f_{c_i}(0)} \right) \right) \end{split} \\ &\sum_{i=1}^{n} \mathbb{1} \left(\log(1-f_{z_i}(0)) + \log(f_{c_i}(y_i)) - \log(1-f_{c_i}(0)) \right) \end{split}$$

Sendo \mathbb{I} a função indicadora que assume o valor 1 se y > 0 e 0 se y = 0 e θ o vetor de parâmetros do modelo (β , γ e ϕ , se houver).

Modelos Hurdle no R I

Neste minicurso utilizaremos principalmente pacote o pscl (Political Science Computational Laboratory, Stanford University)

```
library(pscl)
hurdle(y ~ fc_preditor | fz_preditor, dist = "poisson", zero.dist = "poisson")
```

Modelos Hurdle no R II

Um outro pacote que proporciona diversas funções e podemos adaptar para o ajuste desses modelos é o VGAM (*Vector Generalized Linear and Additive Models*)

Estudos de caso

Vignette v07_hurdle.html

peixe : número de peixes capturados por grupos em um parque estadual

sinistros : número de sinistros em uma seguradora de automóveis

Modelos para Excesso de Zeros **Modelos de Mistura (***Zero Inflated***)**

Modelo Zero Inflated I

- Consideram uma mistura de modelos;
- Os zeros agora são caracterizados em amostrais e estruturais;
- Há contribuição para estimação da probabilidade em zero de duas funções de probabilidade;
- ▶ São chamados de modelos de mistura ou inflacionados de zero (ZI);
- ► Esta abordagem "mistura" um modelo de contagem sem restrição e um modelo censurado à direita no ponto y = 1.

Modelo Zero Inflated II

Distribuição de probabilidades

$$Pr(Y = y) = \begin{cases} f_z(0) + (1 - f_z(0))f_c(Y = y) & \text{se } y = 0, \\ (1 - f_z(0))f_c(Y = y) & \text{se } y = 1, 2, \dots \end{cases}$$

Momentos da distribuição

Média

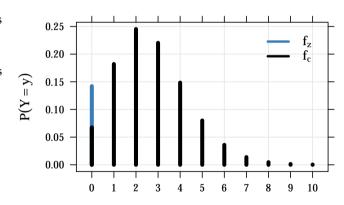
Variância

$$E(Y) = (1 - f_z(0)E(Y^*)$$

$$V(Y) = (1 - f_z(0)E(Y^*)[E(Y^{*2}) - (1 - f_z(0)E^2(Y^*)]$$

Modelos de mistura

- f_z é uma função de probabilidades degenerada no ponto y = 0, ou seja, tem toda massa no ponto 0.
- f_c é uma função de probabilidades tradicional.
- Os modelos de mistura misturam
 f_z e f_c para descrever Y
- Para a parte f_c os dados ainda podem apresentar sub, superdispersão ou excesso de valores em outro ponto.



Misturas comuns

Pode-se propor diferentes distribuições para f_z e f_c . Uma escolha natural para f_z é a Bernoulli e para f_c a Poisson. Assim

$$\begin{aligned} f_z &\sim \text{Bernoulli}(\pi) \\ f_c &\sim \text{Poisson}(\lambda) \end{aligned} \quad \Rightarrow \quad P(Y = y) = \begin{cases} (1-\pi) + \pi e^{-\lambda} & \text{se } y = 0, \\ \pi \left(\frac{e^{-\lambda} \lambda^y}{y!}\right) & \text{se } y = 1, 2, \dots \end{cases}$$

Embora essa escolha de modelo seja o que tem o maior suporte computacional, ressalta-se que outras distribuições podem ser escolhidas para ambas as partes f_z e f_c .

Modelos de regressão Zero Inflated I

- ► Incorporando covariáveis em f_z e f_c na forma $h(Z\gamma)$ e $g(X\beta)$, respectivamente.
- As funções h(.) e g(.), são as funções de ligação escolhidas conforme modelos f_z e f_c .
- ▶ O modelo de regressão *Hurdle* terá, portanto, os vetores de parâmetros β , γ e potencialmente ϕ (caso um modelo com parâmetro de dispersão for considerado)
- ightharpoonup Como agora são modelos misturados a comparação entre β e γ não tem a mesma interpretabilidade.
- ▶ Para comparação de modelos tradicionais contra os modelos de mistura, o teste de Vuong para modelos não aninhados pode ser aplicado.

Modelos de regressão Zero Inflated II

Função de verossimilhança

$$\begin{split} L(\underline{\theta}; \underline{y}) &= \prod_{i=1}^{n} \mathbb{1} \left((1 - f_{z_i}(0)) f_{c_i}(y_i) \right) \cdot \\ &= \prod_{i=1}^{n} (1 - \mathbb{1}) \left(f_{z_i}(0) + (1 - f_{z_i}(0)) f_{c_i}(0) \right) \end{split}$$

Função de log-verossimilhança

$$\begin{split} l(\underline{\theta}; \underline{y}) &= \sum_{i=1}^{n} \mathbb{1} \left(\log(1 - f_{z_i}(0)) + \log(f_{c_i}) \right) + \\ &\sum_{i=1}^{n} (1 - \mathbb{1}) \left(\log(f_{z_i}(0) + (1 - f_{z_i}(0)) f_{c_i}(0)) \right) \end{split}$$

Sendo 1 a função indicadora que assume o valor 1 se y > 0 e 0 se y = 0 e $\underline{\theta}$ o vetor de parâmetros do modelo (β , γ e ϕ , se houver).

Modelos Zero Inflated no R I

Usando o pscl (Political Science Computational Laboratory, Stanford University)

```
library(pscl)
zeroinfl(y ~ fc_preditor | fz_preditor, dist = "poisson", link = "logit")
```

Usando o VGAM (Vector Generalized Linear and Additive Models)

```
library(VGAM)
vglm(y ~ preditor, family = zapoisson)
```

Estudos de caso

Vignette v07_zeroinfl.html

peixe : número de peixes capturados por grupos em um parque estadual

sinistros : número de sinistros em uma seguradora de automóveis

Modelos com Efeitos Aleatórios

Referências I



Conway, R. W., Maxwell, W. L. (1962). A queuing model with state dependent service rates. *Journal of Industrial Engineering*, 12, 132–136.



Paula, G. A. (2013). Modelos de regressão com apoio computacional. IME-USP, São Paulo.



Shmueli, G., Minka, T. P., Kadane, J. B., Borle, S., Boatwright, P. (2005). A useful distribution for fitting discrete data: Revival of the Conway-Maxwell-Poisson distribution. *Journal of the Royal Statistical Society. Series C: Applied Statistics*, 54(1), 127–142.



Zeileis, A., Kleiber, C., Jackman, S. (2008). Regression Models for Count Data in R. *Journal of Statistical Software*, 27(8), 1 - 25. doi:http://dx.doi.org/10.18637/jss.v027.i08



Winkelmann, R. (2008). Econometric analysis of count data (5th Ed.). Springer Science & Business Media.